Herramienta Web para la Clasificación y Recuperación de Información Digital Basada en Etiquetas

Informe de Trabajo Especial de Grado presentado como requisito para optar al título de Licenciado en Computación

Autor: Br. Edinson Padrón Urdaneta

Tutor: MSc. Gerardo Pirela Morillo

Herramienta Web para la Clasificación y Recuperación de Información Digital Basada en Etiquetas

Br. Edinson Padrón Urdaneta Cl. No.: 19.216.488 Teléfono: +58 414 6574149

Venezuela, Zulia, Maracaibo, Urb. La Paz, Calle 96D, Avenida 56 Correo electrónico: edinson.padron.urdaneta@gmail.com

MSc. Gerardo Pirela Morillo Cl.: 12.404.565 Teléfono: +58 412 1734718

Correo electrónico: gepirela@fec.luz.edu.ve

Padrón Urdaneta, Edinson. "Herramienta Web para la Clasificación y Recuperación de Información Digital Basada en Etiquetas". Trabajo Especial de Grado. Universidad del Zulia. Facultad Experimental de Ciencias. División de Programas Especiales. Maracaibo, Venezuela. 2014. 26p.

RESUMEN

Palabras claves: Aplicación web, Etiquetado, Clasificación, Recuperación, Información digital

Correo electrónico: edinson.padron.urdaneta@gmail.com

Padrón Urdaneta, Edinson. "Herramienta Web para la Clasificación y Recuperación de Información Digital Basada en Etiquetas". Trabajo Especial de Grado. Universidad del Zulia. Facultad Experimental de Ciencias. División de Programas Especiales. Maracaibo, Venezuela. 2014. 26p.

ABSTRACT

KeyWords: Web application, Tagging, Classification, Retrieval, Digital information

Email: edinson.padron.urdaneta@gmail.com

ÍNDICE DE CONTENIDO

	Pág.
Resumen	3
Abstract	4
Índice de Tablas	7
Índice de Figuras	8
Introducción	9
Capítulo I. El Problema	
Planteamiento del Problema y Justificación de la Investigación	10
Alcance del problema	12
Objetivos	12
Objetivo General	12
Objetivos Específicos	12
Capítulo II. Marco Teórico	
Antecedentes de la Investigación	13
Tags	13
TagTool	14
Tables	14
Bases Teóricas	15
Sistema de Archivo	15
Transparencia de Localización	
Aplicación Web	16
ORM	
AJAX	
JSON	
WSGI	
Descripción de las Herramientas Usadas	17

Capítulo III. Marco Metodológico	
Descripción de la Metodología Empleada	19
Desarrollo de la Herramienta Balo la Metodología Scrum	20
Distribución de Actividades	20
Capítulo IV. El título de este capítulo	
Referencias bibliográficas	25

ÍNDICE DE TABLAS

F	³ág.
Tabla 1. Cronograma	20

ÍNDICE DE GRÁFICOS

Pág.

INTRODUCCIÓN

CAPÍTULO I

El Problema

1. Planteamiento del Problema y Justificación de la Investigación

La época actual es llamada la "era de la información" (Giuliano, 1983) debido a la relevancia de ésta en la sociedad. Furth (1994) escribió: "La información es actualmente tan vital, y tan intangible, como el aire que respiramos, el cual está lleno de ondas de radio". Hoy en día es el bien más importante y valioso para toda compañía, país y grupo social, por lo que su refinamiento a partir de la abundante cantidad de datos que son creados cada segundo es un proceso primordial y que ofrece una ventaja significativa.

En el año 2010 se produjo y almacenó un estimado de dos exabytes de información (esto incluye todos los medios: libros, revistas, documentos, Internet, fotografías, televisión, radio, música, entre otros) de los cuales, el 93% era digital (Burgin, 2010). Dos años después, la cantidad de información digital generada, se elevó a 2.5 exabytes al día (IBM, 2012), evidenciando un crecimiento exponencial, con la Internet como principal catalizador de este fenómeno.

A la Internet se le suma el creciente uso de dispositivos móviles (teléfonos inteligentes, tabletas, lectores electrónicos, entre otros) que permiten la accesible y cómoda creación y consumo de información gracias a la web, lo cual provoca una cuantiosa producción de datos, además de contribuir con la heterogeneidad y descentralización de los mismos, ocasionando así que su tratamiento sea una tarea penosamente difícil de realizar.

En la actualidad, los distintos repositorios presentan al usuario la información digital en ellos almacenados mediante una estructura jerárquica de directorios en forma de árbol invertido. Esta representación, nacida en 1969 con el lanzamiento del sistema operativo Multics en respuesta a la necesidad de un sistema de almacenamiento secundario en un ambiente de multiprogramación (Multics, 1968), rígida por causa de su inherente propiedad taxonómica, limita la manera en la que puede ser organizada la información, mediante una relación padre-hijo, y hace de la búsqueda de la misma un proceso arduo debido al uso de engorrosas rutas de directorios. Además, esta aproximación dista en gran medida del método natural usado

por el hombre para almacenar y recuperar información de su memoria a largo plazo, el cual consiste en codificarla semánticamente para su almacenamiento (Baddeley, 1966), asociando los datos que percibe (Atkinson y Shiffrin, 1968). Por lo tanto, el ser humano no es una máquina que trabaje en base a datos aislados, éste busca interrelacionarlos, describiéndolos de manera inherentemente subjetiva, breve y dinámica; haciendo necesario un método semejante para clasificar y recuperar la información digital, siendo éste más flexible, intuitivo y natural.

Afortunadamente, la web ha dado origen a un nuevo sistema de clasificación. Originalmente diseñado e implantado por el servicio del.icio.us (Mathes, 2004), el sistema ofrece la posibilidad de describir recursos mediante un conjunto de palabras clave llamadas etiquetas (*tags*, por su término en inglés), las cuales son consideradas por los usuarios como relevantes para caracterizar dichos recursos de acuerdo a sus necesidades sin depender de un vocabulario controlado o de una estructura previamente definida, estableciendo así una relación entre el recurso y un concepto en su mente, con el objeto de organizar el contenido para uso futuro de una manera fácil y flexible (Specia y Motta, 2007). Este esquema de catalogación se ha extendido en uso por una gran variedad de servicios web debido a su popularidad entre los usuarios, quienes ven en éste una manera más natural, sencilla, rápida y personal de clasificar la información digital que les es de interés, hallándola posteriormente con mínimo esfuerzo, siendo ésta una mejor alternativa al problema de darle tratamiento a una gran cantidad de datos, contrastada con la estructura jerárquica que ofrecen los sistemas de archivos modernos.

Hoy en día, existe una serie de herramientas que extienden las capacidades de los sistemas de archivos al permitir el uso de etiquetas; sin embargo, estas herramientas presentan algunas limitaciones, tales como: el tratamiento exclusivo de una fracción de la información digital existente, su operación bajo un número reducido de plataformas, la prestación de un conjunto restringido de funcionalidades, entre otros.

Con este trabajo de investigación se buscó desarrollar una herramienta web integral que garantizara la interoperabilidad entre los distintos sistemas operativos y dispositivos al permitir un acceso convenientemente centralizado a la información digital sin importar la distribución física de ésta, brindando así transparencia de localización mediante el uso de un servidor central que contenga la herramienta y aplicaciones que enlacen los repositorios de los usuarios con dicho servidor. Además, se implantó una manera sencilla, versátil y personal de clasificar

y recuperar la información digital contenida en los mencionados repositorios al permitir su descripción y recuperación mediante el uso de etiquetas definidas a conveniencia. Adaptando así la tecnología nacida en la web al ámbito de los actuales sistemas de archivo.

2. Alcance del problema

La investigación estuvo delimitada al desarrollo de un sistema cliente-servidor donde el cliente, desarrollado para trabajar solo bajo los entornos Windows®, OS X® y Linux®, se comunica con una aplicación web, manteniendo sincronizadas las etiquetas asociadas a los archivos ubicados en los repositorios del usuario, permitiéndole así clasificarlos y recuperarlos mediante el uso de las mencionadas etiquetas.

3. Objetivos

3.1. Objetivo General

 Desarrollar una herramienta web para la clasificación y recuperación de información digital basada en etiquetas

3.2. Objetivos Específicos

- Realizar una revisión documental sobre herramientas de clasificación y recuperación de información digital
- Implementar la aplicación servidor para el almacenamiento y gestión de etiquetas de recursos digitales
- Desarrollar el módulo de la aplicación cliente encargada del rastreo personalizable de la información a etiquetar
- Desarrollar el módulo de la aplicación cliente correspondiente a la interfaz web de usuario
- Realizar las pruebas de caja gris de la herramienta

CAPÍTULO II

Marco Teórico

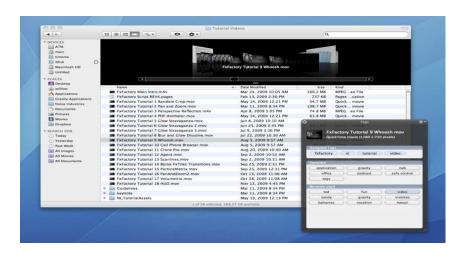
1. Antecedentes de la Investigación

En la actualidad, los sistemas de clasificación basados en etiquetas son ampliamente usados por innumerables aplicaciones web, sin embargo, su uso como complemento a los sistemas de archivo modernos presenta una reducida gama de opciones, dentro de la cual se pueden mencionar:

1.1. Tags

Tags es una aplicación que permite etiquetar archivos y directorios en *finder* (explorador), correos electrónicos en *Mail* (gestor de emails), fotos en *IPhoto* (gestor de imágenes) y enlaces en *Safari* (navegador web); con el objetivo de mantener organizados dichos recursos y poder hallarlos de manera rápida y sencilla.

Tags también ofrece una vista previa de la información, atajos de teclado y una excelente integración con el sistema operativo. Desafortunadamente, esta aplicación solo está disponible para el sistema operativo $OS\ X^{(1)}$, está sujeta a una licencia privativa y no es capaz de sincronizar recursos localizados en dispositivos diferentes.



Gráfica 1. Tags

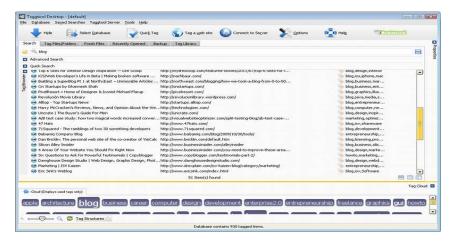
Fuente: Tags (2014)

1.2. TagTool

TaggTool permite añadir etiquetas a archivos, directorios y «bookmarks». Adicionalmente, el usuario puede proporcionar una descripción del recurso, además de una calificación cuantitativa (*rating*). Esta herramienta ofrece la posibilidad de importar metadatos pre-existentes en los recursos y realizar búsquedas en base a estos.

TaggTool también posee una alta integración con el sistema operativo y brinda una vista previa de los recursos gestionados. Además, facilita un sistema de etiquetado automático basado en la naturaleza de los recursos, y muestra una nube de etiquetas para la visualización de las mismas.

Al igual que Tags, TaggTool está sujeto a una licencia privativa y no es capaz de sincronizar recursos localizados en dispositivos diferentes. Otra desventaja que presenta este sistema es que está disponible solo para el sistema operativo *Microsoft Windows*®.



Gráfica 2. TaggTool

Fuente: TaggTool (2014)

1.3. Tables

Tabbles ofrece la posibilidad de clasificar, buscar, organizar y compartir (a través de una LAN o la Internet) archivos, carpetas y «bookmarks», mediante el uso de etiquetas. Adicionalmente, la herramienta ofrece un sistema de auto-etiquetado, además de una excelente integración con el sistema operativo.

A pesar de ser capaz de gestionar, compartir y sincronizar recursos localizados en dispositivos distintos, Tabbles está disponible únicamente para el sistema operativo Microsoft Windows® bajo una licencia privativa.

Gráfica 3. Tabbles



Fuente: Tabbles (2014)

2. Bases Teóricas

2.1. Sistema de Archivo

Un sistema de archivo es un módulo central de todo sistema operativo moderno que consiste de estructuras lógicas y rutinas que controlan la creación, modificación, eliminación y acceso a los datos que residen en una unidad de disco, partición o volumen lógico. Dicho sistema organiza los datos en una estructura jerárquica mediante el uso de directorios, los cuales fungen como contenedores de punteros a múltiples archivos (EMC, 2012). Algunos de los sistemas de archivo más ampliamente usados en la actualidad son: FAT, FAT32, NTFS, HFS Plus, ext2, ext3 y ext4.

2.2. Transparencia de Localización

Se refiere a una consideración de diseño de los sistemas operativos distribuidos. Se habla de transparencia de localización cuando un usuario accede a un recurso en particular sin que sea necesario conocer la ubicación del mismo dentro de la red de trabajo a fin de acceder a él. El no conocer la localización de un recurso implica que todo acceso a éste es realizado por medio de

un nombre que no depende de la ubicación dónde reside actualmente, ni la ubicación dónde fue creado (Borghoff y Schlichter, 2000).

2.3. Aplicación Web

Es una aplicación desarrollada mediante el uso de tecnologías web (html, css, javascript, entre otros) cuyo entorno de ejecución (*runtime enviroment*) está conformado por un motor web (*web engine*). Como ejemplos de este tipo de aplicaciones se pueden mencionar: sistemas de reservación, sitios de compras en línea, juegos, aplicaciones multimedia, mapas, aplicaciones interactivas de diseños, sistemas de correo, entre otros (W3C, 2012).

Los cuatros componentes típicos de una aplicación web son: un navegador, un servidor web, programas de aplicación y un servidor de base de datos. Las responsabilidades del navegador incluyen: presentar una interfaz de usuario, comunicarse con un servidor web, ejecutar *scripts* embebidos, gestionar la *cache* y las *cookies*. El servidor web se encarga, entre otras cosas, de comunicarse con los clientes, proveer contenido estático, invocar programas de aplicación para la generación de contenido dinámico y gestionar las conexiones (Grove, 2009).

CGI, *servlets*, lenguajes de plantilla (*template languages*) y lenguajes de guión (*script languages*) son algunos de los entornos de desarrollo para la construcción de los programas de aplicación mencionados anteriormente, y están típicamente acompañados por un sistema de gestión de base de datos relacional (*RDBMS*, por sus siglas en inglés) accedido por los programas de aplicación a través de un *ODBC / ORM* (Grove, 2009).

2.4. ORM

Es una herramienta que permite conectar un objeto, a veces llamado "modelo de dominio", con una base de datos relacional de manera automática mediante el uso de metadatos como descriptores del objeto y los datos en sí mismos. Algunas de las ventajas que ofrece el uso de un ORM sobre otras técnicas de acceso de datos se listan a continuación: en primer lugar, se automatiza la conversión bidireccional entre objetos y tablas; además, se provee el almacenamiento en *cache* de los objetos de manera transparente en el lado de la aplicación, mejorando así el rendimiento del sistema; y por último, brinda una API de acceso a la base de datos, abstrayendo por completo el sistema de gestión de bases de datos relacional

(Mehta, 2008). *ODB*, *JDBC*, *Peewee*, *SQLAlchemist* y *Yii* son algunos de los ORM usados en la actualidad.

2.5. AJAX

Es una tecnología empleada para prevenir la carga de una página en su totalidad al permitir la transferencia de datos entre el cliente y el servidor web de manera asíncrona, logrando que las páginas se carguen más rápidamente al retrasar la descarga de grandes recursos (Zakas, 2010).

2.6. JSON

Es un formato ligero y fácil de analizar sintácticamente para representar datos, basado en el uso de la sintaxis dispuesta para los literales de tipo arreglo y objeto en el lenguaje de programación JavaScript, usado generalmente para transmitir información entre distintos sistemas de software (Zakas, 2010). La serialización de información estructurada, tarea que se solía realizar con XML, es actualmente llevada a cabo mediante el uso del formato JSON, tendencia que crece con el pasar del tiempo.

2.7. WSGI

Es una interfaz simple y universal entre servidores y aplicaciones web para el lenguaje de programación Python (Eby, 2010). En términos simples, esta especificación establece la CGI (*Common Gateway Interface*) para el lenguaje de programación Python.

3. Descripción de las Herramientas Usadas

- Python: es un lenguaje de programación de código abierto y de propósito general. Cuenta
 con una sintaxis simple y legible. Soporta los paradigmas: orientado a objetos, funcional,
 y procedural. El dominio de aplicación del lenguaje va desde sistemas de administración,
 desarrollo de paginas web, y educación hasta el análisis computacional de inversión, el
 desarrollo de video juegos y el control aéreo (Lutz, 2010).
- Flask: es un *microframework* web para el lenguaje de programación Python. Su principal

característica recae en poseer un conjunto de funcionalidades reducido y simple, brindando gran detalle a la extensibilidad de la herramienta, permitiéndole al usuario elegir los componentes a integrar, adaptándose así a las necesidades del proyecto a desarrollar y a las preferencias de los usuarios de manera flexible e indolora (Flask.org, 2014).

- Pewee: es un ORM simple, escrito en python, que provee una interfaz ligera para realizar consultas SQL (Leifer, 2014).
- SQLite: es una librería que implementa un motor de base de datos SQL transaccional y auto contenido. Sobresale entre sus características el poseer una arquitectura que no concibe la existencia de un proceso servidor, almacenando los datos gestionados en un archivo ordinario (SQLite.org, 2014).
- Twitter bootstrap: es un framework HTML, CSS y JavaScript para desarrollar proyectos web adaptables (responsive) y orientados a dispositivos móviles (mobile first) (getbootstrap.com, 2014).
- JQuery: es una librería escrita en JavaScript rápida, simple y con una gran repertorio de utilidades. Hace de la manipulación del DOM, el manejo de eventos, la creación de animaciones y el uso de Ajax, tareas mucho más sencillas de realizar a través de una API multiplataforma (JQuery.com, 2014).

CAPÍTULO III

Marco Metodológico

1. Descripción de la Metodología Empleada

Para el desarrollo de la herramienta, fruto de esta investigación, se empleó la metodología *Scrum*, la cual se define como un "marco de trabajo en el cual las personas abordan problemas adaptativos complejos, entregando productos del más alto valor posible de manera productiva y creativa". *Scrum* está fundamentada en el empirismo, el cual afirma que el conocimiento viene de la experiencia y que la toma de decisiones debe basarse en lo que se sabe. También, vale mencionar que esta metodología emplea un modelo iterativa e incremental para optimizar la capacidad de predicción y el control de riesgos.

El corazón del *Scrum* es el *Sprint*, el cual es un lapso de tiempo, cuya duración no supera la de un mes, durante el cual un incremento de un producto terminado, usable y potencialmente entregable es creado. Un *Sprint* abarca lo que se va a construir, la elaboración de un plan flexible para llevar a cabo dicho proceso, la construcción en sí misma y el producto resultante.

En cuanto a las pruebas del sistema, se optó por la aplicación de dos tipos: pruebas funcionales orientadas a tareas (*Task-Oriented Functional Tests*) y pruebas de errores forzados (*Forced-Error Tests*), ambas ejecutadas bajo el modelo de caja gris.

De acuerdo a Hung Nguyen, Bob Johnson y Michael Hackett, las pruebas funcionales orientadas a tareas consisten de casos de prueba positivos que son diseñados para verificar las características del programa al asegurarse de que cada una de ellas se comporte como se espera, tomando en cuenta las especificaciones, guías de usuario, requerimientos y documentos de diseño. Cada característica es probada para:

- Validar que la tarea se ejecute adecuadamente dadas condiciones de dato adecuadas bajo condiciones operativas favorables.
- Verificar la integridad del resultado final de la tarea.
- Asegurar la integridad de la característica cuando se usa junto a otras.

Por su parte, las pruebas de errores forzados, según Nguyen, Johnson y Hackett, son casos de prueba negativos diseñados para forzar a un programa a pasar a condiciones de error. Debe generarse una lista de todos los mensajes de error que el programa emite. Esta lista es usada como base en el desarrollo de casos de prueba. Algunas recomendaciones a la hora de llevar a cabo este tipo de pruebas se describen a continuación:

- Verificar que todas las condiciones de error comunes sean detectadas y manejadas correcta y consistentemente.
- Verificar que el programa se recupere correctamente para toda condición de error.
- Verificar que los estados inestables del programa, causados por un error, también sean corregidos.

Por último, el modelo (o pruebas, como también es conocido) de caja gris incorpora elementos de las pruebas de caja negra y blanca. En las pruebas de caja gris se considera el resultado desde el punto de vista del usuario, el conocimiento técnico específico del sistema y el ambiente operativo; además, estas pruebas evalúan el diseño de la aplicación bajo el contexto de la interoperabilidad entre los componentes del sistema.

El modelo de caja gris es ideal para poner a prueba de manera efectiva aplicaciones web debido a que éstas abarcan numerosos componentes, tanto de software como de hardware. Estos componentes deben ser probados en el contexto del diseño del sistema para evaluar su funcionalidad y compatibilidad.

2. Desarrollo de la Herramienta Balo la Metodología Scrum

Tabla 1. Distribución de Actividades

Sprint/Tarea	1°	2°	3º	4°	5°	6°	7°	8°	9°
Diseño e Implementación de la Base de Datos									
Diseño e Implementación de la Interfaz Web de Usuario									
Codificación e Implementación de la Aplicación Servidor									
Codificación e Implementación de la Aplicación Cliente									
Pruebas de Caja Gris de la Herramienta									

Fuente: Padrón (2014)

CAPÍTULO IV

El título de este capítulo

1. El título de esta sección

En primer lugar, se describirán las clases que definen los modelos usados por el módulo servidor. **BaseModel** pauta la interfaz mínima que debe poseer todo modelo, obligando la implementación de tres métodos fundamentales, *exist*, que determina si un registro existe o no; get_by_id , el cual realiza una búsqueda de registros a partir de un conjunto de identificadores; y finalmente, *json*, el cual transforma un registro al formato *json*.

La clase **User** aglomera la información relacionada con el nombre e información de acceso de un usuario del sistema. Las clases **Device**, **Search** y **Tag**, son usadas para representar los dispositivos, búsquedas y etiquetas de los usuarios, respectivamente; estas clases dependen directamente de la clase **User**.

Por su lado, la clase **Resource** sirve para representar los recursos almacenados en los distintos dispositivos de los usuarios. Las clases **TagResources** y **TagSearch** son empleadas para relacionar etiquetas con recursos (en el primer caso) y búsquedas (en el segundo caso).

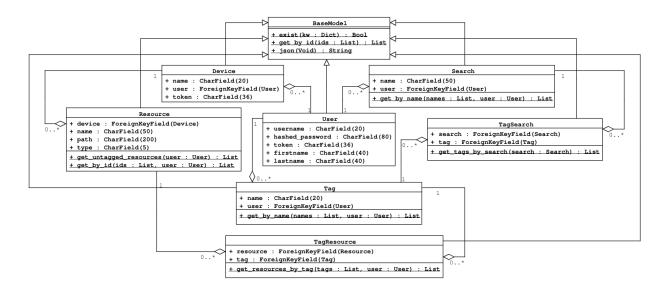
Las anteriores, están plasmadas en el diagrama de clases de la gráfica 4, presentada más abajo; y a excepción de **BaseModel**, corresponden a una y sola una tabla en la base de datos, describiendo en totalidad los modelos implementados en el sistema.

En el caso del módulo cliente, se tiene la clase **Manager**, la cual sirve como pilar fundamental al encargarse de la generación, lectura y respaldo de los archivos de configuración y estado del sistema, así como también de la comunicación con el módulo servidor. El respaldo y comunicación con el servidor se lleva a cabo gracias a las clases **Cache** y **SyncAgent**, respectivamente. Estas tareas corresponden a dos hilos de ejecución independientes, ambos instancias de la clase **DaemonThread**. La clase **Crawler** encapsula las rutinas relacionados con el rastreo de recursos en el dispositivo anfitrión, mientras que la clase **AutoTagger** es la encargada del etiquetado automático de los mencionados recursos.

Por último, **SettingsForm** es una clase empleada en la verificación de los datos enviados por

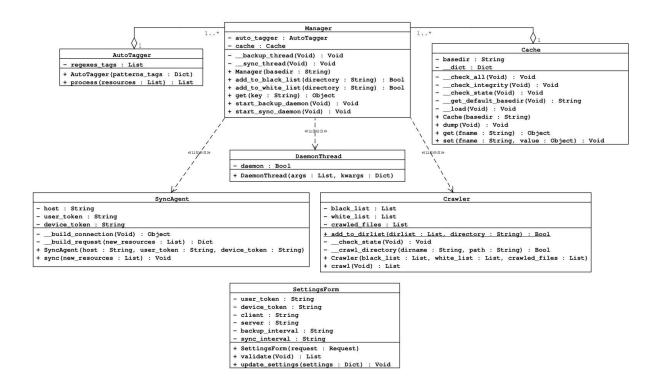
el usuario en el formulario dispuesto para la actualización de los parámetros de configuración del sistema.

Gráfica 4. Diagrama de Clases de los Modelos



Fuente: Padrón (2014)

Gráfica 5. Diagrama de Clases del Módulo Cliente



Fuente: Padrón (2014)

REFERENCIAS BIBLIOGRÁFICAS

- Atkinson, R.C.; Shiffrin, R.M. (1968). Chapter: Human memory: A proposed system and its control processes. The psychology of learning and motivation. pp. 89-195.
- Baddeley, A.D. (1966). The influence of acoustic and semantic similarity on long-term memory for word sequences. The Quarterly Journal of Experimental Psychology. pp. 302-309.
- Burgin, Mark (2010). Theory of Information: Fundamentality, Diversity and Unification. World Scientific. p. VI.
- Furth, J. (1994). The Information Age in Charts, Fortune International.
- Giuliano, V.E. (1983). The United States of America in the Information Age, en Information Policy and Scientific Research, Elsevier, Amsterdam, pp. 59-76.
- IBM (2012) (Página consultada el 25 de junio de 2013) [On-line]. Dirección: www-01.ibm.com/software/data/bigdata/
- Mathes, Adam (2004) (Página consultada el 25 de junio de 2013) [On-line]. Dirección: www.adammathes.com/academic/computer-mediated-communication/folksonomies.html
- Multics (1968) (Página consultada el 25 de junio de 2013) [On-line]. Dirección: www.multicians.org/fjcc4.html
- PC Magazine (2014) (Página consultada el 23 de enero de 2014) [On-line]. Dirección: http://www.pcmag.com/encyclopedia/
- Schwaber, Ken; Sutherland, Jeff (2011). The Definitive Guide to Scrum: The Rules of the Game.
- Specia, Lucia; Motta, Enrico (2007). Integrating Folksonomies with the Semantic Web.
 Knowledge Media Institute The Open University.
- Guenther, Rebecca; Radebaugh, Jaqueline (2004). Understanding Metadata. NISO Press.

• wise GEEK (2014) (Página consultada el 20 de mayo de 2014) [On-line]. Dirección: http://www.wisegeek.com/what-is-location-transparency.htm